

회귀분석 — 한 권의 학습자료

부	다루는 것
1 부	회귀의 의미와 단순선형회귀
2 부	최소제곱법 — 손실함수와 정규방정식
3 부	단순선형회귀 — 다섯 가지 풀이법
4 부	다중회귀 — 행렬로 한 줄에
5 부	회귀의 진단 — 잔차· R^2 ·다중공선성
6 부	규제화의 동기 — 왜 계수를 작게 만드는가
7 부	릿지 회귀 — L^2 규제와 닫힌 해
8 부	라소 회귀 — L^1 규제와 변수 선택
9 부	엘라스틱넷 — 두 규제의 합
10 부	PCR — PCA 와 회귀의 결합
11 부	회귀 가족의 한 자리

1 부. 회귀의 의미와 단순선형회귀

1 장. 회귀란 무엇이며, 어디서 왔는가

회귀분석(regression analysis)의 핵심 질문은 단순하다 — **한 변수의 값을 알 때, 다른 변수의 값을 어떻게 예측·설명할 수 있는가**. 시리얼의 설탕 함량을 알면 소비자 등급이 어느 정도일지 짐작할 수 있다. 학생의 공부 시간을 알면 시험 점수가 어느 정도일지 짐작할 수 있다. 주택의 면적을 알면 가격이 어느 정도일지 짐작할 수 있다. 회귀는 이런 "한 변수로 다른 변수를 짐작하는 일"을 한 직선의 식으로 옮기는 도구다.

1.1 르장드르와 가우스 — 최소제곱법의 탄생 (1805–1809)

회귀의 수학적 뼈대 — 최소제곱법(method of least squares) — 은 1800년대 초의 두 수학자에게서 출발했다.

1805년, 프랑스의 르장드르(Adrien-Marie Legendre, 1752–1833)가 천체역학 책의 부록에서 혜성과 행성의 궤도 자료에서 "가장 잘 맞는 곡선"을 찾는 방법을 처음으로 발표했다. 관측 자료가 잡음을 가지고 있을 때, 곡선과 자료 점 사이의 거리의 **제곱의 합**을 최소화한다는 아이디어였다.

1809년, 독일의 가우스(Carl Friedrich Gauss, 1777–1855)가 "천체운동론"에서 같은 방법을 더 깊이 다듬었다. 가우스는 자신이 1795년부터 이 방법을 사용해 왔다고 주장했고, 더 중요하게는 — 측정 오차가 정규분포(이른바 "가우스 분포")를 따른다고 가정하면 최소제곱 추정값이 곧 최대우도 추정값과 일치한다는 사실을 증명했다. 최소제곱법이 단순한 "좋은 방법"이 아니라 통계적으로 **최적의** 방법임이 이때 드러났다.

두 사람의 작업은 서로 거의 같은 시기에, 서로 모르게 이루어졌지만, 결과는 본질적으로 같았다. 오늘날 최소제곱법은 두 사람 모두의 이름으로 기억된다.

1.2 갈튼과 "회귀" 라는 용어 (1885)

"회귀(regression)" 라는 단어 자체는 르장드르도 가우스도 쓰지 않았다. 이 용어는 그로부터 약 80 년 뒤, 영국의 통계학자 갈튼(Francis Galton, 1822-1911) 이 처음 사용했다.

1885 년, 갈튼은 부모와 자녀의 키 자료를 분석하면서 흥미로운 현상을 발견했다. 매우 큰 부모에게서 태어난 자녀는 평균적으로 부모보다 작았고, 매우 작은 부모에게서 태어난 자녀는 평균적으로 부모보다 컸다. 즉 자녀의 키가 "평균 쪽으로 되돌아가는(regression toward the mean)" 경향이 있었다. 갈튼은 이 현상을 묘사하기 위해 "평균으로의 회귀(regression to the mean)" 라는 표현을 썼고, 부모 키 → 자녀 키 의 관계를 직선으로 적합한 그 직선을 "회귀선(regression line)" 이라 불렀다.

본래 "회귀" 는 "되돌아간다" 라는 갈튼의 발견에 붙은 이름이었지만, 그 직선이 만들어지는 수학적 절차 — 두 변수 사이의 관계를 직선으로 모형화하는 절차 — 가 점차 일반화되면서 "회귀" 라는 단어가 그 절차 자체를 가리키는 표준 용어로 자리잡았다.

오늘날 회귀분석이라 부르면, 그것은 갈튼이 발견한 "평균으로 되돌아감" 의 현상이 아니라, **르장드르·가우스의 최소제곱법으로 두 변수 사이의 직선을 찾는 일** 을 가리킨다. 단어는 갈튼에게서 왔지만 알맹이는 르장드르·가우스에게서 왔다.

1.3 회귀가 답하는 세 가지 질문

회귀분석은 자료에 한 직선을 적합한 뒤, 그 직선으로 세 가지 질문에 답한다.


1. **예측** — x 의 값을 알 때, y 의 값은 얼마쯤 될까? 설탕이 8 g 인 새로운 시리얼이 있다면, 그 등급은 얼마로 짐작되는가?
2. **설명** — x 가 y 를 얼마나 "설명" 하는가? 설탕만 가지고 시리얼 등급의 변동을 몇 퍼센트나 잡아낼 수 있는가?
3. **관계의 방향과 강도** — x 가 1 단위 증가하면 y 는 평균적으로 얼마나 증가(또는 감소) 하는가? 설탕이 1 g 늘 때 등급이 몇 점 떨어지는가?

이 세 질문 모두에 대한 답이 적합한 직선의 "두 수" — 절편과 기울기 — 에 압축되어 있다.

2 장. 두 변수의 산점도

이제 본격적으로 자료를 본다. 시리얼 한 종은 영양 성분과 소비자 등급으로 묘사된다. 77 종의 시리얼 자료 중에서 두 변수 — **설탕 함량(sugars, g)** 과 **소비자 등급(rating)** — 만 골라 좌표평면에 찍어 본다.

시리얼 77 종의 설탕 함량 → 소비자 등급



점들이 "왼쪽 위에서 오른쪽 아래로 비스듬히 내려오는 띠" 처럼 보인다. 설탕 함량이 많은 시리얼일수록 소비자 등급이 낮다는 경향이 한눈에 보인다. 설탕이 0 g 인 시리얼들은 등급이 60 점 이상, 설탕이 12 g 을 넘으면 등급이 30 점 아래로 떨어진다.

이 "비스듬히 내려가는 띠" 의 모양을 한 줄로 요약하고 싶다. 점들의 한가운데를 지나는 한 직선 — 그 직선의 식이 곧 자료의 한 줄짜리 요약이다.

3 장. 직선의 식과 두 모수

자료를 지나는 직선의 식을 다음과 같이 쓴다.

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

여기서 y_i 는 i 번째 시리얼의 실제 등급, x_i 는 같은 시리얼의 설탕 함량이다. β_0 는 직선이 y 축과 만나는 자리 — **절편**(intercept) 이고, β_1 은 직선의 기울기 — **회귀계수**(regression coefficient) 다. ε_i 는 직선이 점들과 정확히 일치하지 않을 때 생기는 **오차**(error) 항이다.


이 식이 가지는 의미를 한 줄씩 풀어 본다.

- β_0 는 $x = 0$ 일 때의 y 의 평균값이다. 설탕이 0 g 인 시리얼의 평균 등급에 해당한다.
- β_1 은 x 가 1 단위 늘 때 y 가 평균적으로 변하는 양이다. 설탕이 1 g 늘 때 등급이 평균적으로 몇 점 변하는지를 가리킨다.
- ε_i 는 모든 자료점이 한 직선 위에 정확히 놓이지 않는다는 사실을 인정하는 항이다. 영양 외의 다른 요인(시리얼 브랜드, 시판 시기, 광고, 측정 잡음) 등이 이 ε 에 모두 흡수된다.

직선 하나는 (β_0, β_1) 단 두 수로 완전히 결정된다. 자료에서 가장 잘 어울리는 한 직선을 찾는다는 것은 결국 가장 잘 어울리는 (β_0, β_1) 두 수를 찾는 일이다.

4 장. 어느 직선이 가장 좋은가 — 잔차의 정의

같은 산점도 위에 세 가지 직선을 그려 본다. 하나는 절편 60, 기울기 -1.5 인 직선 A. 하나는 (지금은 어떻게 구했는지 모르지만 가장 잘 맞는) 최소제곱 적합 직선. 하나는 절편 50, 기울기 -3.0 인 직선 B.



세 직선 모두 "왼쪽 위에서 오른쪽 아래로 내려가는" 추세는 잡고 있다. 그러나 자세히 보면 — A 는 점들의 위쪽으로 살짝 떠 있고, B 는 너무 가파르게 내려가고, 가운데 빨간 직선이 점들의 한가운데를 가장 잘 지나간다.


"가장 잘 어울리는" 이라는 직관을 수학적으로 옮기려면 "점과 직선 사이의 거리" 를 수로 표현해야 한다. 자료의 한 점 (x_i, y_i) 가 직선 위에서 가지는 "예상값" 은 다음과 같다.

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

이 예측값과 실제 y_i 의 차이가 "점과 직선 사이의 세로 거리" 다. 이 차이를 **잔차**(residual) 라 부른다.

$$r_i = y_i - \hat{y}_i = y_i - (\beta_0 + \beta_1 x_i)$$

잔차가 양수이면 점이 직선보다 위에 있다는 뜻이고, 음수이면 직선보다 아래에 있다는 뜻이며, 0 이면 점이 직선 위에 정확히 놓였다는 뜻이다.



위 그림은 적합 직선과 시리얼 일곱 종의 잔차를 노란 세로선으로 보여준다. 100% Bran 시리얼은 적합 직선보다 약 34 점 더 높은 자리에 있고, Cap'n'Crunch 는 직선보다 12.3 점 아래에 있다.

5 장. 잔차 제곱 — 왜 절댓값이 아니라 제곱인가


좋은 직선이란 "모든 점이 가까이 있는 직선" 이다. 즉 잔차의 절댓값이 전체적으로 작은 직선이다. 잔차를 그대로 더하면 양수와 음수가 상쇄돼 0 에 가까워지므로 좋은 척도가 못 된다. 두 가지 표준 대안이 있다.

1. 잔차의 절댓값을 더한다 — L^1 손실, 절댓값 회귀(absolute deviation regression).
2. 잔차를 제곱해서 더한다 — L^2 손실, 최소제곱법.

가우스가 1809 년에 선택한 방법이 후자다. 최소제곱법이 표준이 된 이유는 세 가지가 겹쳐서다. 첫째, 제곱은 모든 자리에서 미분 가능해서 수학적으로 다루기 쉽다. 절댓값은 0 에서 미분이 정의되지 않아 답을 닫힌 형태로 못 구한다. 둘째, 측정 오차가 정규분포를 따른다는 가정 아래에서 최소제곱이 최대우도 추정과 일치한다. 셋째, 답이 행렬 식 하나로 깔끔히 떨어진다.

따라서 "가장 좋은 직선" 은 잔차의 제곱의 합 — **잔차 제곱합**(Sum of Squared Errors, SSE) — 이 가장 작은 직선으로 정의된다.

잔차 → 잔차 제곱 — 점 4개로 본 두 단계



왼쪽 패널은 점에서 직선까지의 세로 거리(잔차) 를 노란 세로선으로, 오른쪽 패널은 각 잔차의 제곱을 그 한 변으로 하는 사각형의 면적으로 보여준다. 사각형이 클수록 점이 직선에서 멀다는 뜻이고, 자료 전체의 "사각형 면적의 총합" 이 곧 SSE 다.

SSE 를 작게 만드는 (β_0, β_1) 한 쌍이 곧 최소제곱 적합 직선의 절편과 기울기다. 그 한 쌍을 어떻게 구하는지가 2 부의 주제다.

2 부. 최소제곱법 — 손실함수와 정규방정식


1 장. 손실함수 SSE 의 정의

자료 n 개의 점에 대해, 직선 (β_0, β_1) 이 만드는 잔차 제곱의 합을 손실함수로 본다.

$$SSE(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

SSE 는 (β_0, β_1) 의 함수다 — 직선을 어떻게 잡느냐에 따라 값이 달라진다. 좋은 직선을 찾는 일이란, SSE 를 가장 작게 만드는 (β_0, β_1) 한 쌍을 찾는 일과 같다.

(β_0, β_1) 의 평면 위에서 SSE 가 어떻게 변하는지를 그려 보면 다음과 같다.



왼쪽이 3 차원 곡면, 오른쪽이 그 곡면을 위에서 본 등고선이다. 곡면의 모양이 "그릇" 처럼 한 점에서 가장 깊게 내려가고, 그 자리 외에서는 어디로 가든 위로 올라간다. 최솟값을 갖는 단 하나의 자리가 곧 최적의 (β_0, β_1) 이다.

본 자료에서는 그 자리가 약 $(59.85, -2.46)$ 부근이다.

2 장. 편미분 = 0 — 정규방정식의 유도

SSE 가 그릇 모양의 곡면이라면, 그릇의 가장 깊은 자리에서는 어느 방향으로 살짝 움직여도 SSE 값이 변하지 않는다 — 그 자리에서 곡면의 "기울기" 가 모든 방향으로 0 이라는 뜻이다. SSE 가 β_0 와 β_1 의 함수이므로, "모든 방향의 기울기가 0" 이라는 조건은 두 변수에 대한 **편미분**(partial derivative) 이 각각 0 이라는 식으로 옮겨진다.

먼저 β_0 에 대한 편미분.

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

다음 β_1 에 대한 편미분.

$$\frac{\partial \text{SSE}}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

각각 식의 양변을 2로 나누고 합 기호 안의 항들을 분배하면 두 식이 깔끔하게 정리된다.

$$\begin{aligned} \sum y_i &= n\beta_0 + \beta_1 \sum x_i \\ \sum x_i y_i &= \beta_0 \sum x_i + \beta_1 \sum x_i^2 \end{aligned}$$

이 두 식을 **정규방정식**(normal equations)이라 부른다. 미지수 두 개 (β_0, β_1)에 대한 일차연립방정식이다.

3 장. 정규방정식의 행렬 표기

정규방정식 두 줄을 한 줄로 묶으려면 행렬을 쓴다. 자료의 모든 점을 한 행렬에 담는다.

자료행렬 X 는 두 열로 구성된다. 첫 열은 모두 1, 둘째 열은 x_i 값들이다. 반응벡터 y 는 y_i 값들을 세로로 늘어놓은 것이다.

$$X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

회귀계수도 벡터 $\beta = (\beta_0, \beta_1)^T$ 로 묶는다. 그러면 정규방정식 두 줄이 다음 한 줄로 떨어진다.

$$X^T X \beta = X^T y$$

$X^T X$ 가 2×2 행렬, $X^T y$ 가 길이 2인 벡터다. $X^T X$ 가 정칙(가역)이라는 조건 하에서, 양변에 그 역행렬을 곱하면 한 줄짜리 닫힌 해가 나온다.

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

이 한 줄이 회귀분석의 모든 식의 출발점이다. 단순선형회귀에서나 다중회귀에서나 — 변수가 한 개든 백 개든 — 같은 식이 똑같이 적용된다. 차이는 단지 X 의 열 수가 늘어나고 β 의 길이가 길어진다는 것뿐이다.

4 장. 단순회귀의 깔끔한 공식

변수가 한 개인 경우(단순선형회귀)에는, 정규방정식 두 줄을 손으로 풀어 β_0 와 β_1 의 닫힌 공식을 얻을 수 있다. 결과는 다음과 같다.

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

위쪽 식이 기울기, 아래쪽 식이 절편이다. 기울기는 "x와 y의 공분산"을 "x의 분산"으로 나눈 것에 정확히 비례한다 — 분자에는 두 변수가 함께 움직이는 정도가 들어가고, 분모에는 x가 혼자 흩어진 정도가 들어간다. x의 흩어짐에 비해 y가 같이 흩어지는 정도가 곧 직선의 기울기다.

절편은 두 평균점 $(\bar{x}, \bar{y})$ 을 적합 직선이 항상 지나가도록 잡힌다. $x = \bar{x}$ 일 때 $y = \bar{y}$ 가 되도록 β_0 가 결정된다는 뜻이다.

3 부. 단순선형회귀 — 다섯 가지 풀이법

같은 자료, 같은 식, 같은 답을 다섯 가지 다른 방법으로 풀어 본다. 각 방법이 "무엇을 어떻게 한다"의 한 단계 한 단계를 끝까지 따라가며, 마지막에 다섯 답이 정확히 일치함을 확인한다.

사용하는 자료는 1부에서 본 시리얼 자료다 — 설탕 함량 x (sugars)에서 등급 y (rating)을 예측하는 문제. 결측치를 제거한 $n = 76$ 개 시리얼.

1 장. 자료 준비

```
import pandas as pd
import numpy as np

# Drive에서 받은 Cereals.csv를 pandas로 읽는다
df = pd.read_csv('Cereals.csv')

# sugars와 rating 두 열만 사용하고, 결측치가 있는 행은 제거
```

```
df = df.dropna(subset=['sugars', 'rating'])

x = df['sugars'].values      # 설탕 함량 (g)
y = df['rating'].values      # 소비자 등급
n = len(x)

print(f'표본 수 n = {n}')
print(f'설탕 평균  $\bar{x}$  = {x.mean():.4f}')
print(f'등급 평균  $\bar{y}$  = {y.mean():.4f}')
```

```
표본 수 n = 76
설탕 평균  $\bar{x}$  = 7.0263
등급 평균  $\bar{y}$  = 42.5583
```

평균 설탕 7.03 g, 평균 등급 42.56 점이다. 이 두 평균점 ($\bar{x}, \bar{y}$) 은 적합 직선이 반드시 지나가는 자리다.

2 장. ① 공식법 — 손으로 한 줄씩

2 부 4 장의 공식 두 줄을 그대로 코드로 옮긴다.

```
xm, ym = x.mean(), y.mean()
Sxx = ((x - xm) ** 2).sum()          #  $\sum (x_i - \bar{x})^2$ 
Sxy = ((x - xm) * (y - ym)).sum()    #  $\sum (x_i - \bar{x})(y_i - \bar{y})$ 

b1 = Sxy / Sxx                      # 기울기
b0 = ym - b1 * xm                   # 절편

print(f' $\sum (x_i - \bar{x})^2 = \{Sxx:.4f\}$ ')
print(f' $\sum (x_i - \bar{x})(y_i - \bar{y}) = \{Sxy:.4f\}$ ')
print(f' $\hat{\beta}_1 = \{b1:.6f\}$ ')
print(f' $\hat{\beta}_0 = \{b0:.6f\}$ ')
```

```
 $\sum (x_i - \bar{x})^2 = 1437.9474$ 
 $\sum (x_i - \bar{x})(y_i - \bar{y}) = -3539.3927$ 
 $\hat{\beta}_1 = -2.461420$ 
 $\hat{\beta}_0 = 59.853017$ 
```

2.1 결과 해석

설탕 함량이 1 g 늘어날 때마다 시리얼 등급은 약 **2.46 점 떨어진다**. 설탕이 0 g 인 가상의 시리얼이 있다면 그 등급은 약 **59.85 점** 이 될 것으로 예측된다. 음의 기울기 -2.46 은 "설탕은 등급의 적" 이라는 자료의 메시지를 한 수로 압축한 것이다.

분자 $\sum(x_i - \bar{x})(y_i - \bar{y})$ 가 음수(-3539) 라는 사실이 곧 두 변수의 공분산이 음수라는 뜻이고, 그것이 "두 변수가 반대 방향으로 함께 움직인다" 라는 의미다. 분모 $\sum(x_i - \bar{x})^2 = 1437.95$ 가 x 의 흠어짐의 정도이고, 분자를 분모로 나누어 단위를 "등급 / 설탕"로 맞춘 것이 기울기다.

3 장. ② 행렬 곱셈 — $\beta = (X^T X)^{-1} X^T y$ 를 손으로

같은 자료에 2부 3장의 행렬 공식을 그대로 적용한다. 열의 처음을 1로 둔 자료행렬 X 를 만들고, $X^T X$ 의 역행렬을 직접 계산한다.

```
# 1 열은 모두 1 (절편 항), 2 열은 x
X = np.column_stack([np.ones(n), x])    # 형태 (76, 2)

XtX = X.T @ X                            # (2, 2) 행렬
Xty = X.T @ y                            # (2,) 벡터

print('X^T X =')
print(XtX)
print('X^T y =', Xty)

XtX_inv = np.linalg.inv(XtX)
beta = XtX_inv @ Xty

print(f'\nβ̂ = ({beta[0]:.6f}, {beta[1]:.6f})')
```

```
X^T X =
[[ 76.  534.]
 [ 534. 5190.]]
X^T y = [ 3234.4309 19186.7401]

β̂ = (59.853017, -2.461420)
```

3.1 결과 해석

$X^T X$ 의 (1,1) 원소가 76 — 표본 수 n — 이고, (1,2) 원소가 534 — $\sum x_i$ — 이고, (2,2) 원소가 5190 — $\sum x_i^2$ — 이다. 즉 $X^T X$ 는 " x 의 기본 통계량 네 가지"를 한 행렬에 담은 것이다.

같은 식으로 $X^T y$ 의 첫 원소는 $\sum y_i$, 둘째 원소는 $\sum x_i y_i$ 다. 자료의 모든 정보가 이 작은 두 행렬·벡터에 압축되어 있고, 그 한 줄의 역행렬 곱셈으로 답이 떨어진다. 공식법과 정확히 같은 (59.853017, -2.461420)이 나온다.

4 장. ③ Cramer 법칙 — 행렬식으로 푸는 일차연립방정식

$X^T X \beta = X^T y$ 는 미지수 두 개에 대한 일차연립방정식이다. 연립방정식을 푸는 고전적 방법이 Cramer 법칙이다. 계수행렬의 행렬식을 분모로, 각 열을 우변으로 교체한 행렬의 행렬식을 분자로 두면 각 미지수가 떨어진다.

```
# 계수행렬의 행렬식
det_XtX = XtX[0,0] * XtX[1,1] - XtX[0,1] * XtX[1,0]

#  $\hat{\beta}_0$  를 풀기 위한 행렬 -  $X^T X$  의 0 번 열을  $X^T y$  로 바꾼다
M0 = XtX.copy()
M0[:, 0] = Xty
det_M0 = M0[0,0] * M0[1,1] - M0[0,1] * M0[1,0]

#  $\hat{\beta}_1$  을 풀기 위한 행렬 -  $X^T X$  의 1 번 열을  $X^T y$  로 바꾼다
M1 = XtX.copy()
M1[:, 1] = Xty
det_M1 = M1[0,0] * M1[1,1] - M1[0,1] * M1[1,0]

b0 = det_M0 / det_XtX
b1 = det_M1 / det_XtX

print(f'det( $X^T X$ ) = {det_XtX:.4f}')
print(f' $\hat{\beta}_0 = \det(M_0)/\det(X^T X) = {b0:.6f}$ ')
print(f' $\hat{\beta}_1 = \det(M_1)/\det(X^T X) = {b1:.6f}$ ')

```

```
det( $X^T X$ ) = 109284.0000
 $\hat{\beta}_0 = \det(M_0)/\det(X^T X) = 59.853017$ 
 $\hat{\beta}_1 = \det(M_1)/\det(X^T X) = -2.461420$ 

```

4.1 결과 해석

$\det(X^T X) = 109284$ 이 0 이 아니라는 사실이 곧 $X^T X$ 가 가역이고 답이 유일하게 존재한다는 보장이다. 설탕 함량 x 가 모든 시리얼에서 같은 값이었다면 두 열이 선형종속이 되어 행렬식이 0 이 되고, 직선의 기울기를 정할 수 없어진다. 자료의 변동(분산)이 회귀분석을 가능하게 하는 근본 조건임이 이 행렬식 한 수에 압축되어 있다.

Cramer 법칙은 2×2 와 3×3 까지는 손으로도 풀 만하지만, 변수가 많아지면 행렬식 자체의 계산이 매우 많아지기 때문에 실용성이 떨어진다. 답이 같다는 사실을 "보여주기" 위한 도구로서의 의미가 더 크다.

5 장. ④ NumPy 의 lstsq — 수치선형대수의 표준 도구

`np.linalg.lstsq` 는 "최소제곱 문제 $X\beta \approx y$ 를 풀어라" 라는 한 줄짜리 명령이다. 내부적으로는 QR 분해 또는 SVD 를 써서 $(X^T X)^{-1}$ 을 명시적으로 계산하지 않고도 답을 구한다 — 수치적으로 더 안정적이다.

```
beta, residuals_sse, rank, sv = np.linalg.lstsq(X, y, rcond=None)

print(f' $\hat{\beta} = ({\beta_0:.6f}, {\beta_1:.6f})$ ')
print(f'잔차 제곱합 SSE = {residuals_sse[0]:.4f}')
print(f' $X$  의 랭크 = {rank}')
print(f' $X$  의 특이값 = {sv}')
```

```
 $\hat{\beta} = (59.853017, -2.461420)$   
잔차 제곱합 SSE = 6217.3615  
X 의 랭크 = 2  
X 의 특이값 = [72.79 6.39]
```

5.1 결과 해석

`lstsq` 가 한꺼번에 네 가지를 돌려준다 — 회귀계수, 잔차 제곱합 SSE, X 의 랭크, X 의 특이값. 랭크가 2 라는 것은 "두 열(상수열, 설탕열) 이 서로 독립이다" 라는 뜻이고, 그것이 곧 유일한 최소제곱해가 존재한다는 보장이다.

특이값 72.79 와 6.39 — 두 값의 비율(약 11배) 이 자료의 "조건수" 와 관련이 있다. 비율이 클수록 $X^T X$ 의 역행렬 이 수치적으로 불안정해진다. 본 자료에서는 안정적이지만, 다중회귀로 가면 이 비율이 매우 커져 "다중공선성" 문제가 발생한다 — 5 부에서 다시 본다.

6 장. ⑤ scikit-learn 의 LinearRegression — 고수준 ML 인터페이스

scikit-learn 은 머신러닝 라이브러리지만, 단순선형회귀도 같은 패턴 `fit` → `predict` 로 제공한다.

```
from sklearn.linear_model import LinearRegression  
  
# sklearn 은 X 를 2 차원 배열로 받는다 - (n, 1)  
reg = LinearRegression()  
reg.fit(x.reshape(-1, 1), y)  
  
print(f' $\hat{\beta}_0$  (intercept_) = {reg.intercept_:.6f}')print(f' $\hat{\beta}_1$  (coef_[0]) = {reg.coef_[0]:.6f}')  
# 예측  
y_pred = reg.predict(x.reshape(-1, 1))  
print(f'\n첫 시리얼 예측값: {y_pred[0]:.4f}, 실제값: {y[0]:.4f}')  
# 적합도  $R^2$   
r2 = reg.score(x.reshape(-1, 1), y)  
print(f' $R^2$  = {r2:.4f}')
```

```
 $\hat{\beta}_0$  (intercept_) = 59.853017  
 $\hat{\beta}_1$  (coef_[0]) = -2.461420  
  
첫 시리얼 예측값: 45.0844, 실제값: 68.4030  
 $R^2$  = 0.5835
```

6.1 결과 해석

sklearn 도 같은 답을 준다. 내부적으로 NumPy 의 `lstsq` 와 비슷한 수치 선형대수를 사용하지만, "학습된 모형 객체" 라는 개념을 제공한다는 차이가 있다. 같은 모형을 새 자료에 `predict` 로 즉시 적용할 수 있고, 회귀와 분류·정규화·교차검증 같은 다른 도구들과 같은 인터페이스로 묶일 수 있다.

$R^2 = 0.5835$ 는 본 모형이 설탕 함량 한 변수만으로 시리얼 등급의 변동을 약 **58.4% 설명한다** 는 뜻이다. 나머지 41.6%의 변동은 단백질, 식이섬유, 나트륨, 칼륨, 비타민 같은 다른 영양 변수와 측정 잡음에서 온다. 이 점이 4부에서 다중회귀로 넘어가야 할 동기를 만든다.

7 장. 다섯 답의 비교 — 정확히 같다

같은 자료에 다섯 가지 방법을 적용한 결과를 한 표에 모은다.

방법	β_0 (절편)	β_1 (기울기)
① 공식법	59.853017	-2.461420
② 행렬 곱셈 $(X^T X)^{-1} X^T y$	59.853017	-2.461420
③ Cramer 법칙	59.853017	-2.461420
④ NumPy <code>lstsq</code>	59.853017	-2.461420
⑤ scikit-learn <code>LinearRegression</code>	59.853017	-2.461420

소수점 여섯째 자리까지 정확히 같다. 같은 최소제곱 문제의 답을 다섯 가지 다른 길로 구했지만, 모두 "SSE 가 최소가 되는 단 하나의 자리"에 도달했다는 뜻이다.

7.1 방법 선택의 기준 — 어느 것을 언제 쓰는가

상황	권장 방법
변수가 1 개, 손으로 풀이 과정을 보여줄 때	① 공식법
변수가 2~5 개, 행렬 곱셈을 직접 보여줄 때	② 행렬 곱셈
행렬식의 의미를 강조할 때 (교육용)	③ Cramer 법칙
변수가 많거나 $X^T X$ 가 거의 비가역일 때	④ NumPy <code>lstsq</code>
다른 ML 모형과 같은 인터페이스로 묶을 때	⑤ scikit-learn

실용에서는 ④ 와 ⑤ 가 표준이다. ① ~ ③ 은 "왜 답이 그런 모양으로 나오는가"를 설명하는 도구로서의 가치가 크다. 답이 같음을 한 번 확인하고 나면, 그 다음부터는 어느 도구를 쓰든 같은 결과가 나온다는 사실을 잊지 않는 것이 중요하다.

7.2 적합 직선의 한 줄 요약

다섯 풀이법이 모두 다음 한 줄을 가리킨다.

$$\text{rating} \approx 59.85 - 2.46 \times \text{sugars} \quad (R^2 = 0.58, n = 76)$$

설탕이 1 g 늘 때마다 등급이 2.46 점 떨어지고, 모형이 자료의 약 58% 를 설명한다는 한 줄 요약이다. 나머지 42% 를 잡으려면 변수를 추가해야 한다 — 그 자리가 4 부 다중회귀다.

4 부. 다중회귀 — 행렬로 한 줄에

1 장. 왜 변수를 늘리는가 — 한 변수의 한계

3 부에서 설탕(sugars) 한 변수만으로 시리얼 등급을 설명했다. 결과는 $R^2 = 0.58$ — 자료의 약 58% 를 잡았다는 뜻이지만, 뒤집어 말하면 **42% 의 변동을 설명하지 못했다**. 적합 직선에서 30 점 이상 벗어나는 시리얼이 여럿이고, 같은 설탕 함량(예: 3 g) 을 가진 시리얼들의 등급도 30 점 ~ 65 점 사이로 크게 다르다.

설탕 외에 또 무엇이 등급에 영향을 줄까? 자료에는 13 개의 영양 변수가 더 있다 — calories, protein, fat, sodium, fiber, carbo, potass, vitamins, weight, cups, shelf 등. 이들 중 어느 것이 설탕과 별도로 등급에 추가 정보를 주는지 모른다. 설탕 한 변수만 가지고는 "설탕이 같아도 식이섬유가 많은 시리얼은 등급이 높다" 같은 사실을 잡아낼 수 없다.

다중회귀(multiple regression) 는 여러 변수를 한꺼번에 고려해서, 각 변수의 "독립적인 기여도" 를 분리해 낸다. 설탕이 1 g 늘 때 등급이 떨어지는 정도를 — **다른 영양 성분이 모두 같다는 가정 아래** — 따로 잰다. 이 "다른 변수를 고정한 상태에서의 효과" 라는 개념이 다중회귀의 핵심이다.

2 장. 변수 두 개 — 평면이 된다

먼저 변수를 한 개 늘려서 두 변수의 경우부터 본다. 설탕과 식이섬유(fiber) 두 변수로 등급을 설명하는 모형은 다음과 같다.

$$y_i = \beta_0 + \beta_1 \cdot \text{sugars}_i + \beta_2 \cdot \text{fiber}_i + \varepsilon_i$$

기하적으로 보면 — 이 식은 (x_1, x_2, y) 의 3 차원 공간에서 한 **평면**의 식이다. 단순회귀가 (x, y) 평면에서의 한 직선이었다면, 변수가 둘이면 그 "직선" 이 한 차원 올라간 "평면" 이 된다. 자료의 점들이 3 차원 공간에 흩어져 있고, 그 점들 한가운데를 지나는 평면 한 장의 식을 찾는 일이다.

평면의 식은 세 수 $(\beta_0, \beta_1, \beta_2)$ 로 결정된다. β_1 은 "설탕이 1 g 늘 때 등급이 변하는 양 — 단, 식이섬유가 같다는 조건 아래" 이고, β_2 는 "식이섬유가 1 g 늘 때 등급이 변하는 양 — 단, 설탕이 같다는 조건 아래" 다. 두 변수의 효과가 서로 분리되어 있다.

3 장. 변수 p 개 — 같은 식이 행렬로 한 줄에

변수가 p 개로 늘어나면 식은 다음과 같다.

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i$$

미지수 ($\beta_0, \beta_1, \dots, \beta_p$) 가 $p + 1$ 개로 늘어났다. 변수가 백 개라면 β 가 백한 개다. 손으로 적기에는 너무 길다.

이때 행렬 표기가 모든 것을 한 줄로 바꾼다. 자료행렬 X 의 첫 열은 모두 1 (절편 항), 나머지 p 열은 각 설명변수의 값이다. 반응벡터 y , 계수벡터 β 도 같이 묶는다.

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

그러면 모든 n 개의 관측식이 한 줄로 묶인다.

$$y = X\beta + \varepsilon$$

변수가 한 개든 백 개든 식이 정확히 같다. 단순회귀와 다중회귀가 같은 기하학적 문제 — "평면(혹은 초평면) 으로 자료 점을 설명하는 일" — 임이 이 한 줄의 표기에서 분명해진다.

4 장. 다중회귀의 정규방정식과 닫힌 해

손실함수 SSE 의 정의도 그대로다 — 잔차 벡터의 제곱합.

$$SSE(\beta) = \|y - X\beta\|^2 = (y - X\beta)^T(y - X\beta)$$

이것을 β 에 대해 미분해서 0 으로 두면, 단순회귀의 정규방정식과 똑같은 모양이 나온다.

$$X^T X \beta = X^T y$$

그리고 닫힌 해도 정확히 같은 식이다.

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

차이는 단 하나 — $X^T X$ 가 2×2 가 아니라 $(p+1) \times (p+1)$ 의 더 큰 행렬이고, β 가 길이 2 가 아니라 길이 $p+1$ 의 더 긴 벡터다. 같은 식, 더 큰 행렬.

5 장. Cereals 13 영양 변수로 다중회귀

Drive 에서 받은 같은 자료에 13 영양 변수를 모두 넣고 다중회귀를 돌린다. 결측치가 있는 행은 제거.

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression

df = pd.read_csv('Cereals.csv').dropna()          # 결측 모두 제거
features = ['calories', 'protein', 'fat', 'sodium', 'fiber',
            'carbo', 'sugars', 'potass', 'vitamins',
            'shelf', 'weight', 'cups']
X = df[features].values                          # (n, 12)
y = df['rating'].values
n, p = X.shape
print(f'표본 수 n = {n}, 변수 수 p = {p}')

# 행렬 곱셈으로 직접
X_design = np.column_stack([np.ones(n), X])      # (n, p+1)
beta = np.linalg.inv(X_design.T @ X_design) @ X_design.T @ y
print(f'\n $\beta^{\wedge}$ (절편 포함):')
print(f' intercept = {beta[0]:.4f}')
for name, b in zip(features, beta[1:]):
    print(f' {name:10s} = {b:+.4f}')

# sklearn 으로
reg = LinearRegression()
reg.fit(X, y)
y_pred = reg.predict(X)
sst = ((y - y.mean())**2).sum()
sse = ((y - y_pred)**2).sum()
r2 = 1 - sse / sst
print(f'\nSST = {sst:.2f}, SSE = {sse:.2f}, R2 = {r2:.4f}')
```

표본 수 $n = 74$, 변수 수 $p = 12$

$\beta^{\wedge}$ (절편 포함):

intercept	= 54.9264
calories	= -0.2226
protein	= +3.2729
fat	= -1.6914
sodium	= -0.0543
fiber	= +3.4439

```

carbo      = +1.0922
sugars     = -0.7244
potass     = -0.0341
vitamins   = -0.0512
shelf      = -0.0143
weight     = -0.4664
cups       = +0.0173

```

SST = 14470.04, SSE = 50.65, $R^2 = 0.9965$

5.1 결과 해석

전체 적합도. $R^2 = 0.9965$ — 시리얼 등급의 99.6%가 13개 영양 변수로 설명된다. 단순회귀의 $R^2 = 0.58$ 에서 거의 1.0까지 올라갔다. 잃어버린 변동의 거의 전부가 다른 변수들에 흩어져 있었다는 뜻이다.

개별 계수의 해석. 계수의 부호와 크기를 한 줄씩 읽으면 자료가 무엇을 말하고 있는지가 드러난다.

- **단백질** $\beta = +3.27$, **식이섬유** $\beta = +3.44$ — 두 변수가 가장 강한 "등급 상승" 효과를 가진다. 다른 영양 성분이 같다면 단백질 1g 증가가 등급 3.3점 상승과 연결된다.
- **설탕** $\beta = -0.72$ — 단순회귀에서 -2.46이었던 설탕의 계수가 다중회귀에서는 -0.72로 작아졌다. 단순회귀의 "설탕 효과" 중 일부가 다른 변수(식이섬유 부족, 칼로리 과다 등)와의 상관 때문이었음을 의미한다. 설탕 자체의 "순수한" 효과는 -0.72 정도다.
- **지방** $\beta = -1.69$ — 지방이 1g 늘 때 등급이 1.69점 떨어진다.
- **칼로리, 나트륨, 칼륨, 비타민**의 계수는 -0.05 ~ -0.22 정도로 작다. 계수가 작은 이유는 두 가지가 가능하다 — (1) 그 변수의 실제 영향이 작거나, (2) 단위가 커서 "1 단위 증가"가 자료의 정상 범위 밖이기 때문. 나트륨의 범위(0~320 mg)를 생각하면 $-0.054 \times 320 = -17$ 점 정도이므로 작지 않다. 계수만 보고 "중요도"를 판단할 수 없다는 사실이 5부의 핵심 주제이다.

조심할 점. 다중회귀의 계수는 "다른 변수가 모두 같다는 가정 아래"의 효과다. 본 자료에서 칼로리와 단백질이 강한 상관을 가지므로, "칼로리는 같지만 단백질만 다른" 시리얼이 실제로는 거의 없다. 그런 자료에서 다중회귀 계수를 단독으로 해석하면 **다중공선성(multicollinearity)**의 함정에 빠지기 쉽다. 이 문제와 그 해결책이 5부와 6부의 주제다.

5.2 단순회귀 vs 다중회귀 — 한눈에

비교 항목	단순회귀 (sugars만)	다중회귀 (13 변수)
변수 수 p	1	12
절편 β_0	59.85	54.93
sugars 계수	-2.46	-0.72
R^2	0.583	0.997
잔차 표준오차	9.17	0.91

같은 "sugars의 효과"가 단순회귀에서 -2.46, 다중회귀에서 -0.72로 크게 다르다. 단순회귀의 -2.46은 "설탕의 직접 효과 + 설탕과 상관된 다른 변수의 간접 효과"가 모두 섞인 값이고, 다중회귀의 -0.72는 "다른 변수를 일정하게 두었을 때의 설탕의 순수한 효과"다. 어느 것이 옳은 답인가는 "무엇을 묻고 있는가"에 달려 있다.

- "설탕을 많이 먹는 시리얼은 등급이 낮은가?" — 단순회귀가 답한다 (-2.46).
- "같은 영양 조건에서 설탕만 늘리면 등급이 어떻게 변하는가?" — 다중회귀가 답한다 (-0.72).

두 답이 다르다는 사실이 곧 자료에 변수 간 상관이 존재한다는 증거다. 이 "상관된 변수들의 효과를 어떻게 깔끔히 분리할 것인가"가 다중회귀의 가장 어려운 부분이고, 다중공선성· R^2 ·잔차 진단·규제화로 이어지는 모든 길의 출발점이다.